# TP Schéma Physique et Optimisation

March 18, 2024

# 1 TP BD Avancée

ANAS CHAKIR 2A ISI G4

#### ABDELHADI NASMANE 2A ISI G4

MAROUANE AKASSAB 2A ISI G4 Ce travail a été réalisé en équipe de 3.

# 1.1 EXERCICE 1

# Question A:

[]: CREATE TABLE clientsA AS SELECT \* FROM clients; CREATE TABLE commandesA AS SELECT \* FROM commandes;

1									
Id   Opera	tion	Name	Rows	I	Bytes	(	Cost (গ	%CPU)	Time
* 1   HASH  * 2   TAB	T STATEMENT   JOIN   LE ACCESS FULL  LE ACCESS FULL		9 9 1 830	į Į	369 369 22 15770	į Į	10 10 3 7	(0) (0)	00:00:01 00:00:01 00:00:01 00:00:01
PLAN_TABLE_OU									
Predicate Inf	ormation (ident	ified by oper	ation i	d)	) : 				
	("CL"."CODECLIE ("CL"."CONTACT"			")	)				

Interpretation: On utilise pas d'index, donc on a pas d'optimistion.

#### Question B:

```
[]: CREATE TABLE clientsB AS SELECT * FROM clients;
    CREATE TABLE commandesB AS SELECT * FROM commandes;
    CREATE INDEX index_sec_trie1 ON clientsB(codeclient);
    CREATE INDEX index_sec_trie2 ON clientsB(contact);
    CREATE INDEX index_sec_trie3 ON commandesB(codeclient);
```

Id   Operation	Name	Rows	Bytes	Cost (	(%CPU)	Time	. <u>.</u>
0   SELECT STATEMENT  * 1   HASH JOIN   2   TABLE ACCESS BY INDEX ROWID BATCHED  * 3   INDEX RANGE SCAN   4   TABLE ACCESS FULL	CLIENTSB INDEX_SEC_TRIE2 COMMANDESB	9   9   1   1   830	369   369   22       	9 9 2 1 7	(0) (0) (0)	00:00:01 00:00:01 00:00:01 00:00:01 00:00:01	
PLAN_TABLE_OUTPUT  Predicate Information (identified by operation	ı id):						
l - access("CL"."CODECLIENT"="CO"."CODECLIE 3 - access("CL"."CONTACT"='Thomas Hardy')	ENT")						

Interpretation: On remarque que l'utilisation de l'index secondaire sur l'attribut clientB.contact car la condition de sélection est une égalité, donc en utilisant l'index secondaire on trouve bien le résultat avec un coût optimal (ex: recherche dichotomique).

index\_sec\_trie1 est négligé car le chemin d'accès choisi pour accéder à la table clients est index\_sec\_tri2 car il est de cardinalité 1.

index\_sec\_trie3 négligé puisque le Hash Join nécessitera dans ce cas de traverser des pointeurs supplémentaires, donc c'est mieux de le faire par un parcours séquentiel sans avoir à faire la traversée de pointeurs.

# Question C:

```
[]: CREATE cluster cluster1 (codeclientindex CHAR(5));
CREATE INDEX index_primaire_1 ON CLUSTER cluster1;
CREATE TABLE clientsC CLUSTER cluster1(codeclient) AS SELECT * FROM clients;
CREATE INDEX index_sec_trie1 ON clientsC(contact);
CREATE TABLE commandesC AS SELECT * FROM commandes;
CREATE INDEX index_sec_trie2 ON commandesC(codeclient);
```

Id   Operation	Name	Rows	Bytes	Cost (	(%CPU)	Time	 
0   SELECT STATEMENT  * 1   HASH JOIN   2   TABLE ACCESS BY INDEX ROWID BATCHED  * 3   INDEX RANGE SCAN   4   TABLE ACCESS FULL	CLIENTSC INDEX_SEC_TRIE1 COMMANDESC	9   9   1   1   830	387   387   24     15770	10 10 3 1 7	(0) (0) (0)	00:00:01 00:00:01 00:00:01 00:00:01 00:00:01	İ
PLAN_TABLE_OUTPUT							
Predicate Information (identified by operation	id):						
1 - access("CL"."CODECLIENT"="CO"."CODECLIE 3 - access("CL"."CONTACT"='Thomas Hardy')	ENT")						

**Interpretation:** Même justification que la question précédente.

#### Question D:

```
[]: CREATE cluster cluster1 (contactindex VARCHAR2(30));
CREATE INDEX index_primaire_1 ON CLUSTER cluster1;
CREATE TABLE clientsD CLUSTER cluster1(contact) AS SELECT * FROM clients;
CREATE INDEX index_sec_trie1 ON clientsD(codeclient);
CREATE TABLE commandesD AS SELECT * FROM commandes;
CREATE INDEX index_sec_trie2 ON commandesD(codeclient);
```

```
| Id | Operation
                   | Name
                                               | Rows | Bytes | Cost (%CPU)| Time
                                                           344 | 9 (0)| 00:00:01 |
344 | 9 (0)| 00:00:01 |
24 | 2 (0)| 00:00:01 |
1 (0)| 00:00:01 |
   0 | SELECT STATEMENT
                                                       8 I
* 1 | HASH JOIN
                                                      8 344
                                                    1 |
   2 | TABLE ACCESS CLUSTER| CLIENTSD
          INDEX UNIQUE SCAN | INDEX_PRIMAIRE_1 |
   3 1
   4 | TABLE ACCESS FULL | COMMANDESD | 830 | 15770 |
                                                                      7 (0) 00:00:01
PLAN TABLE OUTPUT
Predicate Information (identified by operation id):
  1 - access("CL"."CODECLIENT"="CO"."CODECLIENT")
   3 - access("CL"."CONTACT"='Thomas Hardy')
```

**Interpretation:** Même justification que la question précédente, la différence est qu'ici on a utilisé l'index primaire au lieu de l'index secondaire sur clientsD.contact.

#### Question E:

```
[]: CREATE cluster cluster1 (codeclientindex CHAR(5));
CREATE INDEX index_primaire_jointure_trie ON CLUSTER cluster1;
CREATE TABLE clientsE CLUSTER cluster1(codeclient) AS SELECT * FROM clients;
CREATE TABLE commandesE CLUSTER cluster1(codeclient) AS SELECT * FROM commandes;
CREATE INDEX index_sec_trie1 ON clientsE(contact);
```

**Interpretation:** On accède à clientsE par l'index secondaire trié puisque la cardinalité estimé du résultat est égale à 1 ce qui est optimal. De plus, l'optimiseur estime que l'accès par l'index primaire de jointure trié à commandesE donnera 15 lignes, ce qui est beacoup mieux que les 830

lignes données par le parcours sequentiel, car elle est dans le même cluster que clientsE et grâce à l'index on pourra faire la jointure rapidement.

L'utilisation du Nested Loop car c'est la plus simple et la plus rapide. Un hash Join perdra du temps à construire la table de hachage et que le join n'implique pas d'autres entrée/sortie supplémentaires.

# Question F:

```
[]: CREATE CLUSTER cluster1(contactindex VARCHAR2(30)) SINGLE TABLE HASHKEYS 80;
CREATE TABLE clientsF CLUSTER cluster1(contact) AS SELECT * FROM clients;
CREATE INDEX index_sec_trie1 ON clientsF(codeclient);
CREATE TABLE commandesF AS SELECT * FROM commandes;
CREATE INDEX index_sec_trie2 ON commandesF(codeclient);
```

Id	Operation	Name	Rows	1	Bytes	1	Cost	(%CPU)	Time
0     1     2    * 3	SELECT STATEMENT NESTED LOOPS TABLE ACCESS FULL TABLE ACCESS HASH		13 13 830 1	į	559 559 15770 24	İ	7		
<del>-</del>	BLE_OUTPUT								
Predica	te Information (iden	tified by oper	ation :	1d.	):				
	access("CL"."CONTACT filter("CL"."CODECLI			Τ"]	)				

Interpretation: La différence entre cette démarche et celle de la question D, c'est qu'on utilise un index hashé sur clientsF.contact au lieu d'un index trié.

L'utilisation d'une Nested Loop est optimal, puisqu'on doit faire un parcours inévitable des 830 lignes.

# Question G:

```
[]: CREATE CLUSTER cluster1(codeclientindex CHAR(5)) SINGLE TABLE HASHKEYS 80;
CREATE TABLE clientsG CLUSTER cluster1(codeclient) AS SELECT * FROM clients;
CREATE INDEX index_sec_trie1 ON clientsG(contact);
CREATE TABLE commandesG AS SELECT * FROM commandes;
CREATE INDEX index_sec_trie2 ON commandesG(codeclient);
```

Id	Operation	Name	Rows	 	Bytes	Cos	 t (%	CPU)	Time
0     1     2    * 3	SELECT STATEMENT   NESTED LOOPS   TABLE ACCESS FULL  TABLE ACCESS HASH		9 9 830 1	į	387 387 15770 24	į I		(0)	00:00:01 00:00:01 00:00:01
<del>-</del>	BLE_OUTPUT te Information (ident	ified by oper	ation :	 id)	) :				
	access("CL"."CODECLIE filter("CL"."CONTACT"			T")	)				

Interpretation: La différence entre cette démarche et celle de la question C, c'est que ici on utilise un index hashé sur clientsG.contact au lieu d'un index trié.

L'utilisation d'une Nested Loop est optimal, puisqu'on doit faire un parcours inévitable des 830 lignes.

#### Question H:

```
[]: CREATE CLUSTER cluster1(codeclientindex CHAR(5)) HASHKEYS 80;
CREATE TABLE clientsH CLUSTER cluster1(codeclient) AS SELECT * FROM clients;
CREATE TABLE commandesH CLUSTER cluster1(codeclient) AS SELECT * FROM commandes;
CREATE INDEX index_sec_trie1 ON clientsH(contact);
```

Id   Operation	Name	Rows	Bytes	Cost	(%CPU)	Time
0   SELECT STATEMENT     1   NESTED LOOPS    * 2   TABLE ACCESS FULL   * 3   TABLE ACCESS HASH  PLAN TABLE OUTPUT		14 14 1 14	742 24	2	7 (0)	00:00:01 00:00:01 00:00:01
Predicate Information (ident  2 - filter("CL"."CONTACT"  3 - access("CL"."CODECLIE	='Thomas Hard	y')				

**Interpretation:** On accéde à clientsH.contact par l'index secondaire trié puisque la cardinalité estimé du résultat est égale à 1 ce qui est optimal.

L'utilisation de l'index hashé est pire que l'index trié de la Question E, puisqu'on doit hasher puis chercher le tuple correspondant dans l'autre table, dans le paquet correspondant, ce ce qui explique le coût élevé par rapport au schéma de la Question E.

L'utilisation du Nested Loop car c'est la plus simple et la plus rapide. Un hash Join perdrait du temps à construire la table de hachage et que le join n'implique pas d'autre entrée/sortie.

## Question I:

```
[]: CREATE TABLE clientsI AS SELECT * FROM clients;

CREATE INDEX index_sec_trie1 ON clientsI (codeclient);

CREATE INDEX index_sec_trie2 ON clientsI (contact);

CREATE TABLE commandesI AS SELECT * FROM commandes;

CREATE INDEX index_sec_trie3 ON commandesI (codeclient, datecomm, nocomm);
```

```
| Id | Operation
                                      | Name | Rows | Bytes | Cost (%CPU)| Time
                                                                           3 (0)| 00:00:01 |
   0 | SELECT STATEMENT
                                                            9 |
                                                                  369 I
                                                                        3 (0)| 00:00.01
3 (0)| 00:00:01
2 (0)| 00:00:01
                                                             9 |
                                                                  369 I
   1 | NESTED LOOPS
  2 | TABLE ACCESS BY INDEX ROWID BATCHED| CLIENTSI
                                       INDEX RANGE SCAN | INDEX_SEC_TRIE2 |
                                                                               (0) | 00:00:01
* 4 | INDEX RANGE SCAN
                                                                         1 (0) 00:00:01
PLAN TABLE OUTPUT
Predicate Information (identified by operation id):
  3 - access("CL"."CONTACT"='Thomas Hardy')
  4 - access("CL"."CODECLIENT"="CO"."CODECLIENT")
```

Interpretation: L'optimiseur ici a choisi d'utiliser une Nested Loop au lieu de Hash join qui était utilisé dans la Question B, cela explique l'utilisation de l'index multiattributs puisque la condition de jointure va être appliqué sur la table commandes avant de faire la jointure.

D'où le coût minimal.

#### Question J:

```
[]: CREATE TABLE clientsJ AS SELECT * FROM clients;
    CREATE INDEX index_sec_trie1 ON clientsJ (codeclient);
    CREATE INDEX index_sec_trie2 ON clientsJ (contact);
    CREATE TABLE commandesJ AS SELECT * FROM commandes;
    CREATE INDEX index_sec_trie3 ON commandesJ (datecomm, nocomm, codeclient);
```

Interpretation: Les performances du schéma de la Question I sont mieux que celles de la Question J. Cela est expliqué par le changement de l'ordre des attributs de l'index trié puisque la

condition de jointure nécessite un tri de l'attribut commande I.codeclient mais le tri des autres attributs n'est pas important.

## 1.2 EXERCICE 2

#### Question A:

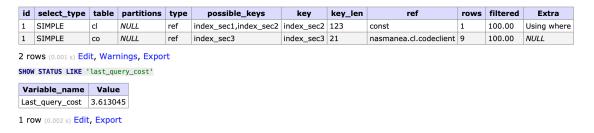


id	select_type	table	partitions	type	possible_keys	key	key_len	ref	rows	filtered	Extra	
1	SIMPLE	cl	NULL	ALL	NULL	NULL	NULL	NULL	91	10.00	Using where	
1	SIMPLE	со	NULL	ALL	NULL NULL NULL 830 10.00 Using where; Using join buffer (hash j							
SHOW	WS (0.006 s) Edi	last_qu	ery_cost'	rt								
var	iable_name	Valu	ie									
Last_query_cost 766.910180												

**Interpretation:** On utilise pas d'index, donc pas d'optimistion.

# Question B:





Interpretation: On remarque l'utilisation de l'index secondaire sur l'attribut clientB.contact, puisque la condition de sélection est une égalité, donc en utilisant l'index secondaire on trouvera le résultat avec un coût optimal (ex: recherche dichotomique).

De même, l'optimiseur utilise l'index sec trie3 pour accéder à commandesB.codeclient.

index\_sec\_trie1 est négligé car le chemin d'accès choisi pour clients est index\_sec\_tri2 car il est de cardinalité 1.

#### Question C:



id	select_type	table	partitions	type	possible_keys	key	key_len	ref	rows	filtered	Extra
1	SIMPLE	cl	NULL	const	PRIMARY,index_sec1	PRIMARY	122	const	1	100.00	NULL
1	SIMPLE	со	NULL	ref	index_sec2	index_sec2	21	const	14	100.00	NULL
	ows (0.001 s) Ed	•		t							
Va	riable_name	Value	•								
Las	t_query_cost	4.8990	00								

**Interpretation:** Même justification que la question précédente, à part l'utilisation de l'index primaire au lieu de l'index secondaire.

#### Question D:

1 row (0.002 s) Edit, Export



id	select_type	table	partitions	type	possible_keys	key	key_len	ref	rows	filtered	Extra		
1	SIMPLE	cl	NULL	ref	PRIMARY,index_sec1	index_sec1	123	const	1	100.00	Using index		
1 SIMPLE co NULL ALL NULL NULL NULL 830 10.00 Using where; Using join buffer									Using where; Using join buffer (hash join)				
SHOV	2 rows (0.004 s) Edit, Warnings, Export SHOW STATUS LIKE 'last_query_cost'												
	riable_name	<b>Valu</b>											
	Last_query_cost 85.600227												

Interpretation: Ici on a le choix entre deux chemin d'accès à la table clientsD. L'optimiseur choisit l'index secondaire sur clientsD.contact puisque la cardinalité estimée du resultat est égale à 1 ce qui est optimal, on n'utilise pas l'index primaire car on a unicité du chemin d'accès.

Le coût augmente significativement puisqu'on fait un FULL SCAN sur la deuxième table.

#### Question E:

```
[]: ALTER TABLE clientsE ADD PRIMARY KEY (codeclient);
    CREATE INDEX index_sec1 ON clientsE (contact);
    CREATE INDEX index_sec2 ON commandesE (codeclient);

EXPLAIN SELECT co.nocomm, co.datecomm
FROM clientsE cl, commandesE co
WHERE cl.codeclient = co.codeclient
AND cl.contact = 'Thomas Hardy';
SHOW STATUS LIKE 'last_query_cost';
```

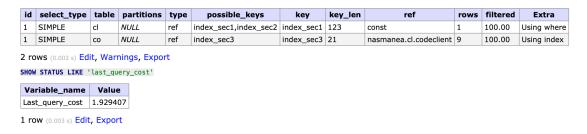
id	select_type	table	partitions	type	possible_keys	key	key_len	ref	rows	filtered	Extra
1	SIMPLE	cl	NULL	ref	PRIMARY,index_sec1	index_sec1	123	const	1	100.00	Using index
1	SIMPLE	со	NULL	ref	index_sec2	index_sec2	21	nasmanea.cl.codeclient	9	100.00	NULL
SHOW	WS (0.001 s) Edi STATUS LIKE '	•	ery_cost'	t							
Las	t_query_cost	3.6130	45								
1 ro	w (0.002 s) Edit	, Expor	t								

Interpretation: On est dans les même circonstances de la Question D, mais cette fois on a un index secondaire sur commandes E. codeclient, donc on a pas le problème du FULL SCAN, d'où le coût diminue.

## Question F:

```
[]: CREATE INDEX index_sec1 ON clientsF (contact);
    CREATE INDEX index_sec2 ON clientsF (codeclient);
    CREATE INDEX index_sec3 ON commandesF (codeclient, datecomm, nocomm);

EXPLAIN SELECT co.nocomm, co.datecomm
    FROM clientsF cl, commandesF co
    WHERE cl.codeclient = co.codeclient
    AND cl.contact = 'Thomas Hardy';
    SHOW STATUS LIKE 'last_query_cost';
```



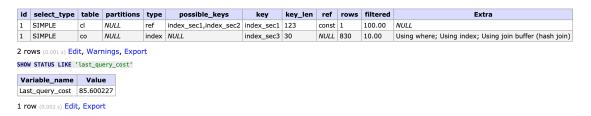
**Interpretation:** Ici on choisit l'index secondaire clientsF.contact pour accéder à la table clientF, car la cardinalité estimée est 1, on n'utilise pas l'index secondaire index\_sec2 sur clientsF.codeclient

car on a unicité du chemin d'accès.

On utilise de plus l'index tripet pour accéder à la table commandeF. On remarque une baisse significative du coût.

#### Question G:





Interpretation: Ici on choisit l'index secondaire clientsG.contact pour accéder à la table clientsG, car la cardinalité estimée est 1, on n'utilise pas l'index secondaire index\_sec2 sur clientsG.codeclient car on a unicité du chemin d'accès.

On utilise de plus l'index tripet pour accéder à la table commandeG. Le coût se dégrade par rapport au coût de la requête de la Question E, puisque l'ordre de l'index multiattributs n'est pas bien choisi, puisqu'on a intêret à avoir commandesG.codeclient trié, les autres attributs étant non important.

## Question H:



id select_type	table	partitions	type	possible_keys	key	key_len	ref	rows	filtered	Extra
1 SIMPLE	cl	NULL	index	PRIMARY	PRIMARY	142	NULL	91	10.00	Using where; Using index
SIMPLE	со	NULL	ref	index_sec1	index_sec1	21	nasmanea.cl.codeclient	9	100.00	NULL
HOW STATUS LIKE	· tast_qu	ery_cost.								

**Interpretation:** On utilise l'index secondaire sur commandes H. codeclient pour accéder à la table commandes H.

Encore une fois, le choix de l'ordre de l'index multiattribut n'est pas optimal, on devrait avoir clientH.contact comme premier attribut pour construire l'index. Le coût est élevé.

# Question I:



id	select_type	table	partitions	type	possible_keys	key	key_len	ref	rows	filtered	Extra
1	SIMPLE	cl	NULL	ref	PRIMARY	PRIMARY	122	const	1	100.00	Using index
1	SIMPLE	со	NULL	ref	index_sec1	index_sec1	21	nasmanea.cl.codeclient	9	100.00	NULL
SHOW	ws (0.001 s) Edi STATUS LIKE '		ery_cost'	t							
Las	t_query_cost	3.6130	45								
1 ro	w (0.002 s) <b>Edit</b>	, Expor	t								

Interpretation: On utilise l'index secondaire sur commandes H. codeclient pour accéder à la table commandes H.

Contrairement à la Question H, le choix de l'ordre de l'index multiattribut est bon, d'où le coût diminue.

## 1.3 EXERCICE 3

# Requête 1:

```
[]: CREATE INDEX index_sec1 ON clients1 (codeclient, societe, ville, pays);
    CREATE INDEX index_sec2 ON commandes1 (codeclient, datecomm);

EXPLAIN SELECT cl.codeclient, cl.societe, cl.ville, cl.pays
    FROM clients1 cl, commandes1 co
    WHERE cl.codeclient = co.codeclient
    AND YEAR(co.datecomm) = 1997;
    SHOW STATUS LIKE 'last_query_cost';
```

Coût: 152 (7564 Sans Optimisation) On est dans les même conditions de l'Exercice 2, donc on a choisi de suivre la même démarche de la Question F qui était la meilleure selon nos conclusions.

# Requête 2:

```
[]: ALTER TABLE produits1 ADD PRIMARY KEY (prixunit, refprod, nom);

EXPLAIN SELECT refprod, nom, prixunit
FROM produits1
WHERE prixunit BETWEEN 80 AND 100;
SHOW STATUS LIKE 'last_query_cost';
```

Coût : 2.87 (7.94 Sans Optimisation) De même, comme la question précédente, a part l'utilisation de l'index primaire au lieu de l'index secondaire (On trouve un coût de 2.92 en utilisant l'index secondaire)

# Requête 3:

```
[]: EXPLAIN Select p.refprod, p.nom, c.nom, f.contact
   FROM produits1 p, categories1 c, fournisseurs1 f
   WHERE p.nocat = c.nocat
   AND p.nofourn = f.nofourn
   AND p.indisp = 0
   ORDER BY c.nom ASC;
   SHOW STATUS LIKE 'last_query_cost';
```

Coût : 59 Experimentalement, tous les schémas d'optimisation qu'on a essayé sont moins perfromants que le schéma sans optimisation.

#### Requête 4:

```
CREATE INDEX index_sec1 ON clients1 (pays, codeclient, societe);
CREATE INDEX index_sec2 ON detailcomm1 (nocomm, refprod);
CREATE INDEX index_sec3 ON produits1 (refprod, nom, prixunit);

EXPLAIN Select det.nocomm, p.nom, p.prixunit, e.nom, cl.societe, m.nom
FROM detailcomm1 det, commandes1 co, clients1 cl, produits1 p , messagers1 m, employes1 e
WHERE p.refprod = det.refprod
AND det.nocomm = co.nocomm
AND co.noemp = e.noemp
AND co.codeclient = cl.codeclient
AND co.nomsgr = m.nomsgr
AND cl.pays = 'Italie';
SHOW STATUS LIKE 'last_query_cost';
```

Coût : 961 (3 722 884 Sans Optimisation !) Encore une fois, on a comparé différents schémas, celui qu'on a utilisé dans l'Exercice 2 Question F, était le meilleur. (C'était le premier qu'on a testé)